U.PORTO
FACULDADE DE CIÊNCIAS
UNIVERSIDADE DO PORTO

REINFORCEMENT LEARNING

Introdução aos Sistemas Inteligentes e Autónomos

19 de dezembro de 2024

Grupo H:

Beatriz Fonseca	up202205826
Beatriz Moreira	up202208293
Inês Neves	up202206252

Contextualização e descrição do problema

- **Environment**: *Lunar Lander*, *Gymnasium.*

- **States**:
  - **obs[0]**: posição em relação ao eixo do x;
  - **obs[1]**: posição em relação ao eixo do y;
  - **obs[2]**: velocidade no eixo do x;
  - **obs[3]**: velocidade no eixo do y;
  - **obs[4]**: ângulo de rotação do módulo;
  - **obs[5]**: velocidade angular do módulo;
  - **obs[6]**: estado da perna esquerda
    (0 se tocou no solo ou 1 se não tocou no solo);
  - **obs[7]**: estado da perna direita
    (0 se tocou no solo ou 1 se não tocou no solo).

- **Actions:**
  - **0**: Não faz nada;
  - **1**: Liga o propulsor principal;
  - **2**: Liga o propulsor esquerdo;
  - **3**: Liga o propulsor direito.

- **Rewards:**
  - **Aumenta/ diminui** quanto mais **próximo/afastado** estiver da plataforma;
  - **Aumenta/diminui** quanto mais **lento/rápido** for o movimento;
  - **Diminui** quanto **mais inclinado** o agente estiver, em relação ao plano **horizontal**;
  - **+10** pontos por cada perna em contacto com o solo;
  - **-0.03** pontos por frame, em que o propulsor **lateral** esteja ativo;
  - **-0.3** pontos por frame, em que o propulsor **principal** esteja ativo;
  - **+100** pontos se aterrar de forma segura;
  - **-100** pontos se cair;
  - Um episódio é considerado bem sucedido, caso o agente conquiste, pelo menos **200** pontos.

Escolha do Algoritmo

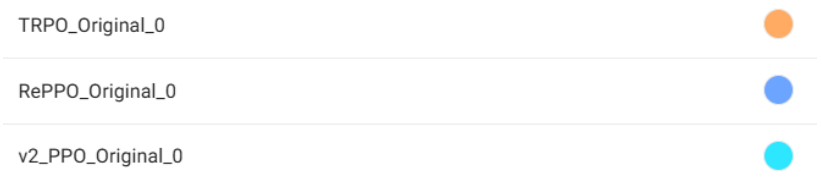

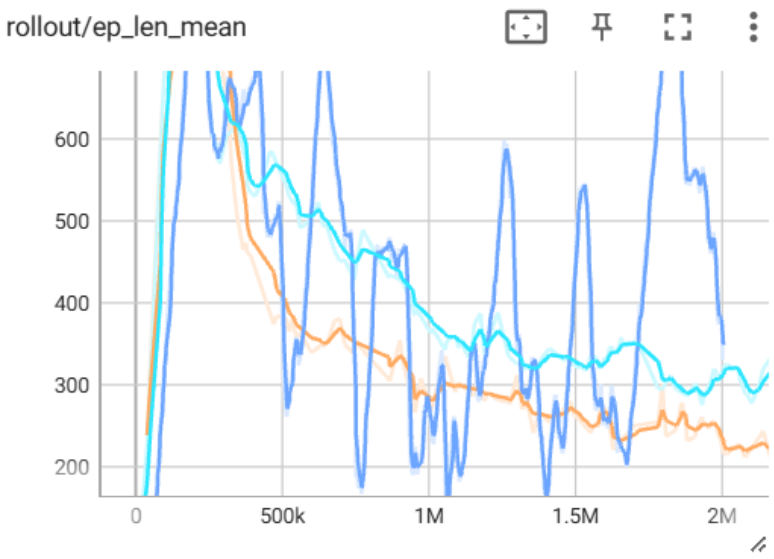

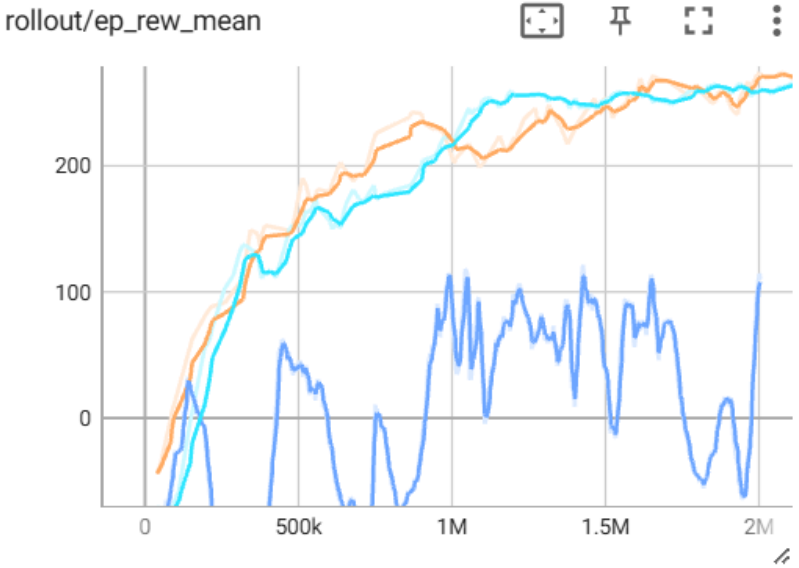

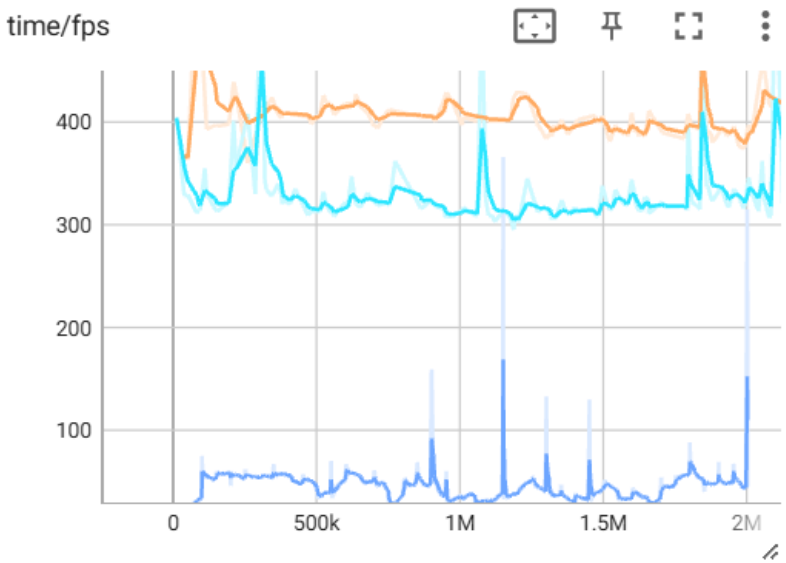

- Testamos os seguinte modelos: TRPO, RePPO e PPO.
- Corremos os modelos até atingir 2M de iterações.
- Com base nos gráficos, escolhemos testar as nossas alterações no modelo TRPO, por apresentar maior estabilidade e desempenho.
- Este algoritmo alcança recompensas mais altas, reduzindo eficazmente o comprimento dos episódios. Além disso, o TRPO mostra ser mais estável comparativamente com o RePPO, que tem flutuações significativas, e com o PPO, que apresenta um menor desempenho.

Modificações nos Rewards

- **Rewards1**:

Aterrar na plataforma

- aterrar centrado na plataforma: **+10** → **+60**
  - aterrar com apenas um pé: **+10**
  - aterrar com os dois pés: **+50**
    - velocidade horizontal e vertical suave: **+50**
    - se não for suave: **-100**
    - não aterrar com os dois pés na plataforma: **-100**
- aterrar fora da plataforma: **-100**

- **Rewards2**:

Aterrar na plataforma

- aterrar centrado na plataforma: **+10** → **+60**
  - aterrar com apenas um pé: **+10**
  - aterrar com os dois pés: **+50**
    - velocidade horizontal e vertical suave: **+50**
    - se não for suave: **-100**
    - velocidade angular suave: **+50**
    - se não for suave: **-100**
  - não aterrar com os dois pés na plataforma: **-100**
- aterrar fora da plataforma: **-100**

Análise de resultados

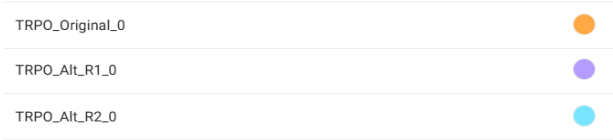

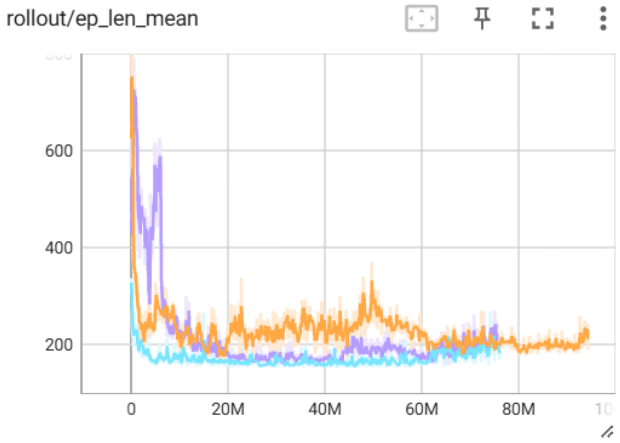

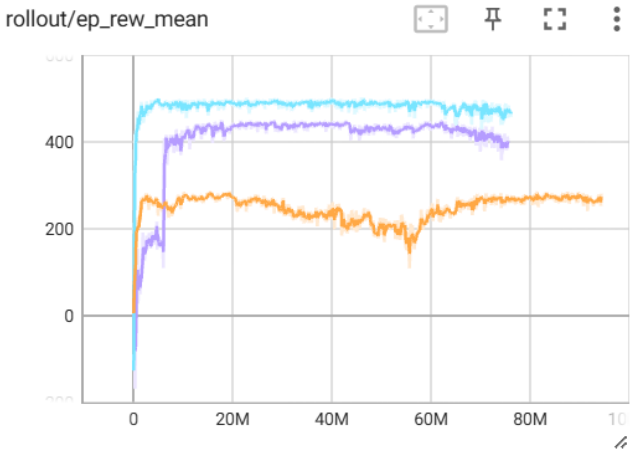

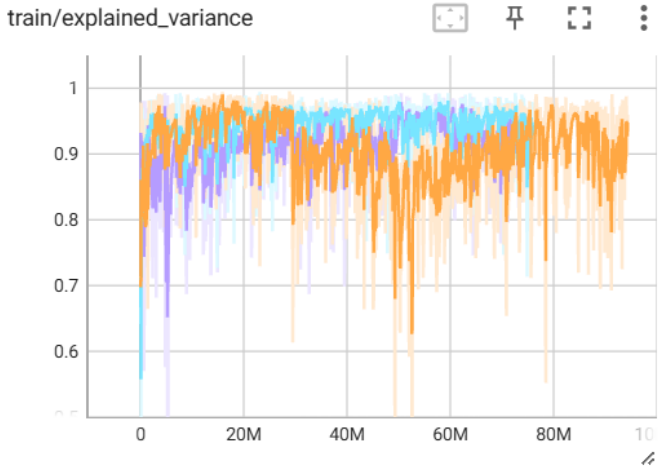

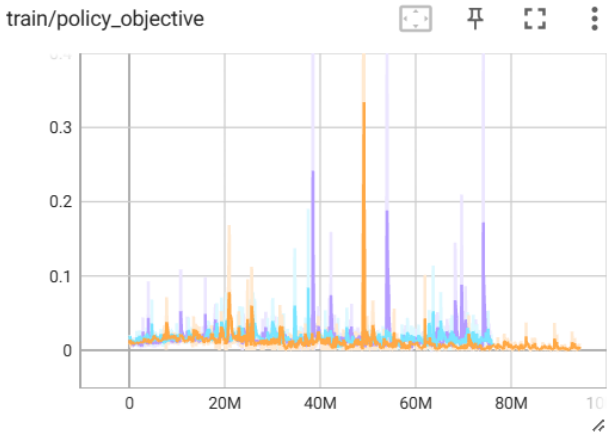

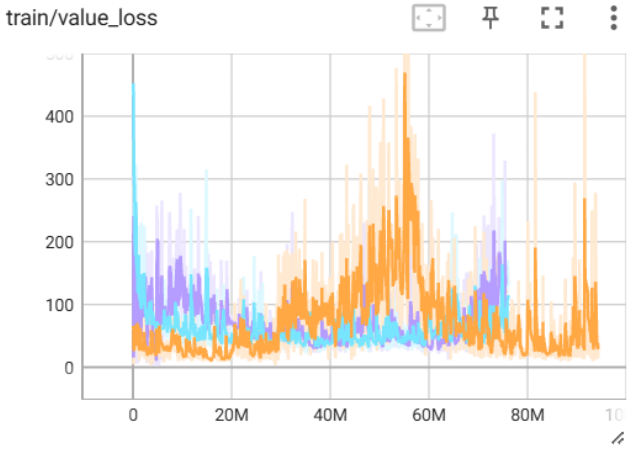

- Com base na análise gráfica concluímos que o modelo TRPO_Alt_R1 se destaca em termos de desempenho, quando comparado com os restantes algoritmos.
- Este apresenta uma elevada recompensa média, estabilidade no treino e um baixo erro na função value_loss.
- Apesar de o TRPO_Alt_R2 mostrar um desempenho competitivo, também podemos observar alguma instabilidade em algumas métricas, tornando-o menos eficaz em aplicações reais no contexto do Lunar Lander.

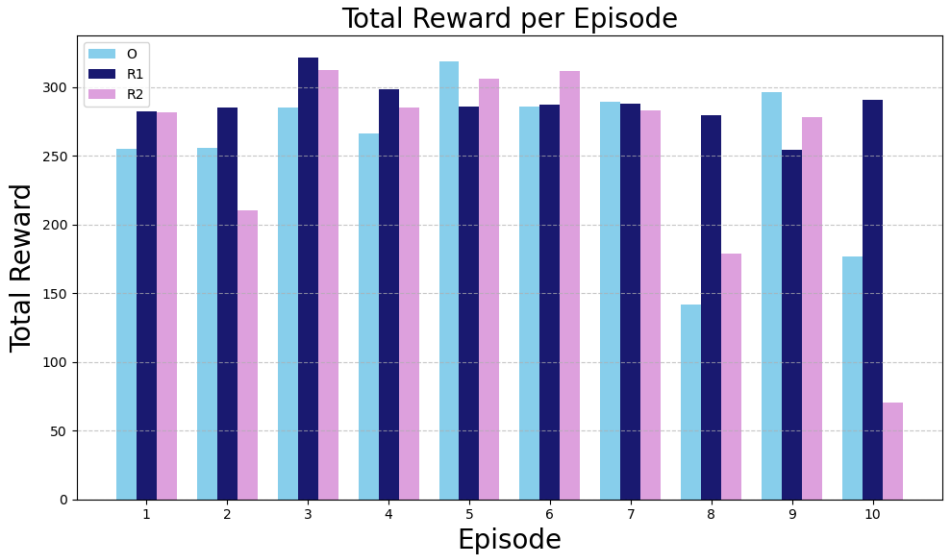

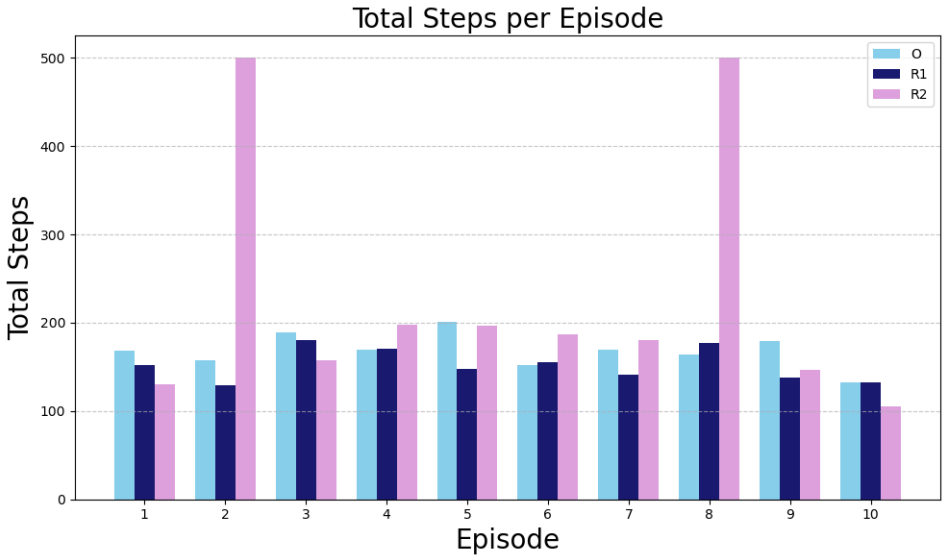

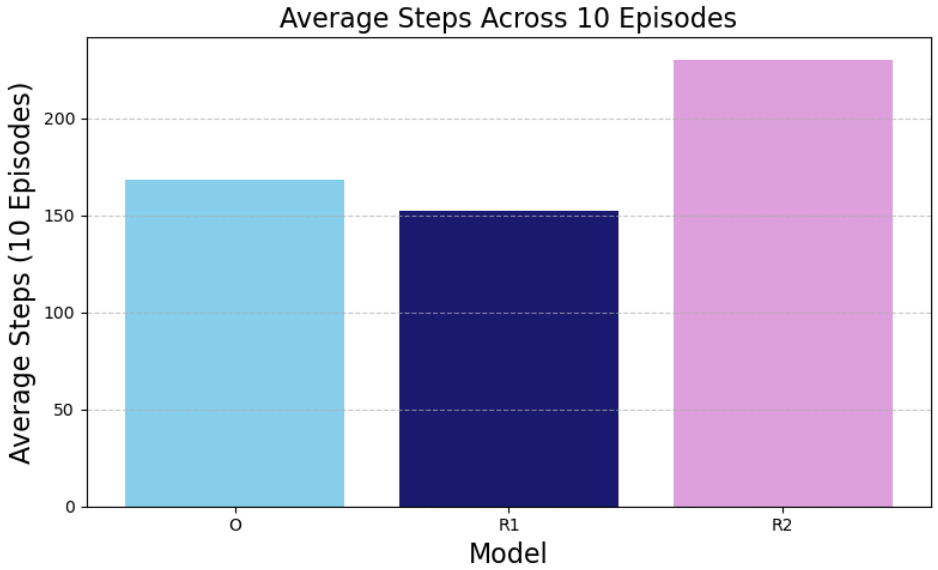

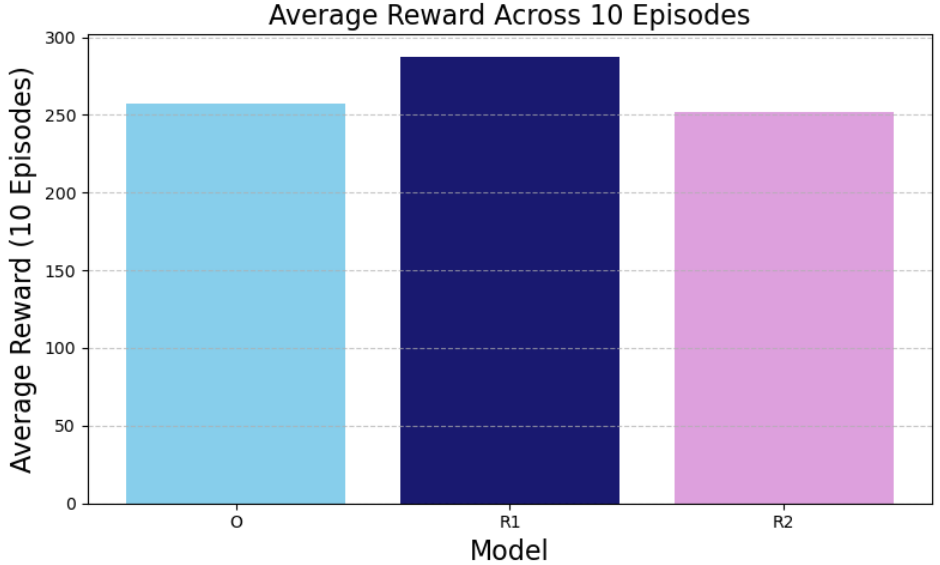

- O TRPO R1 apresenta o melhor desempenho, alcançando as maiores recompensas médias, com o menor número de time steps, por episódio.
- O TRPO original apresenta resultados estáveis, no entanto inferiores.
- O TRPO R2 revela uma maior inconsistência, com variações significativas quanto ao número de time steps e recompensas.

Otimização de hiperparâmetros

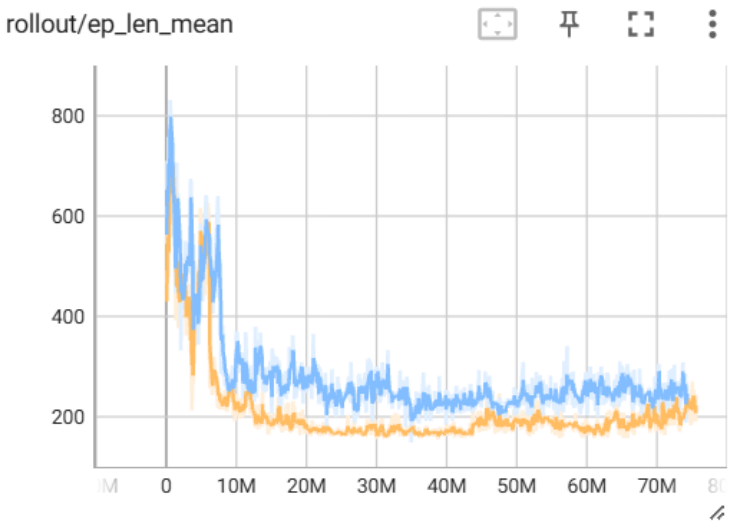

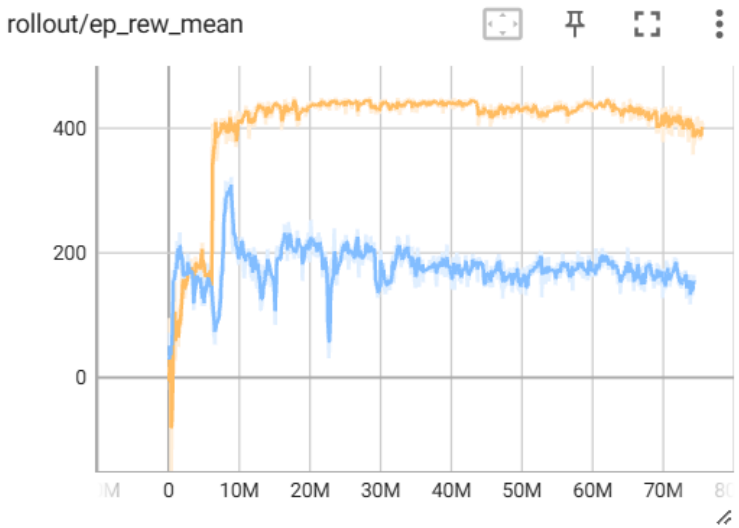

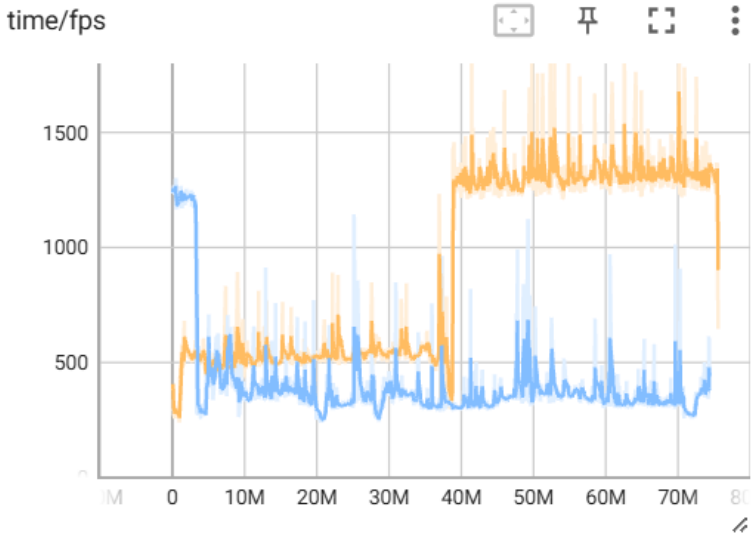

Decidimos testar outros valores para os seguintes hiperparâmetros:

- learning_rate – [1e-4, 1e-2] → 0.00025014249743408705
- batch_size – ([1024, 2048, 4096]) → 4096
- gae_lambda –[0.9, 1.0] → 0.9121520984243334
- gamma – [0.95, 0.999] → 0.9809022197654524

Efeito das alterações

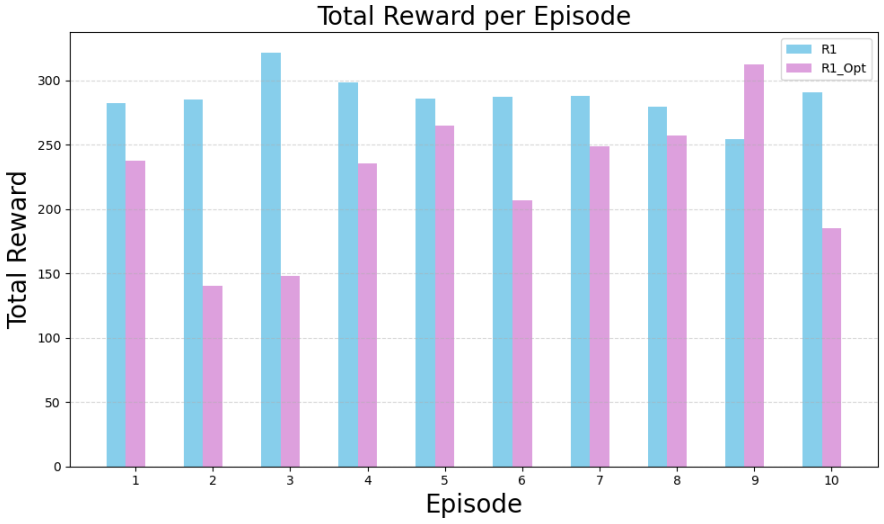

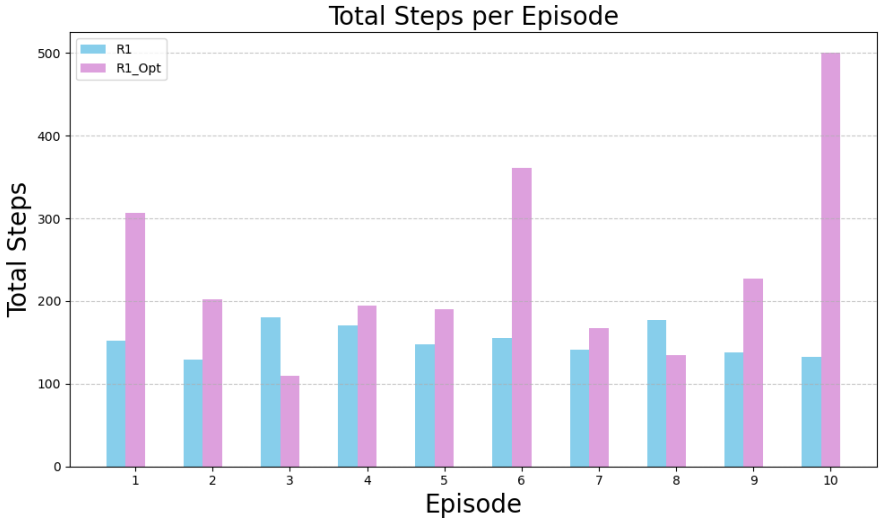

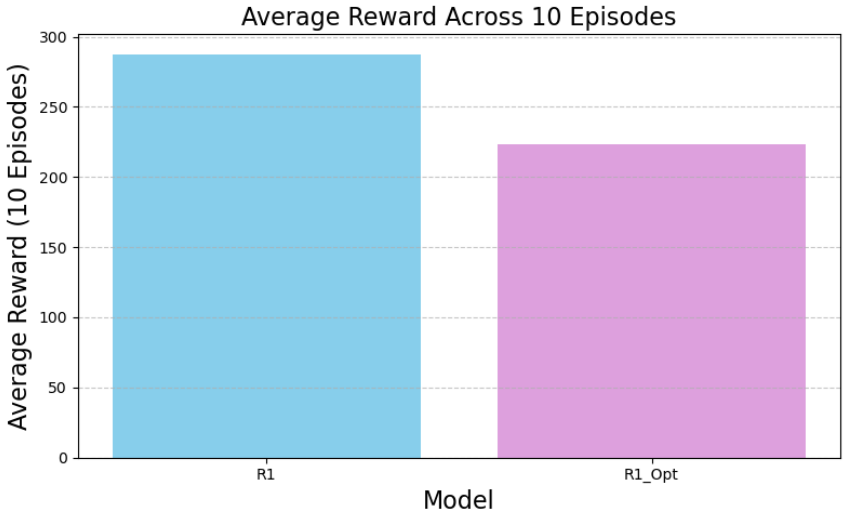

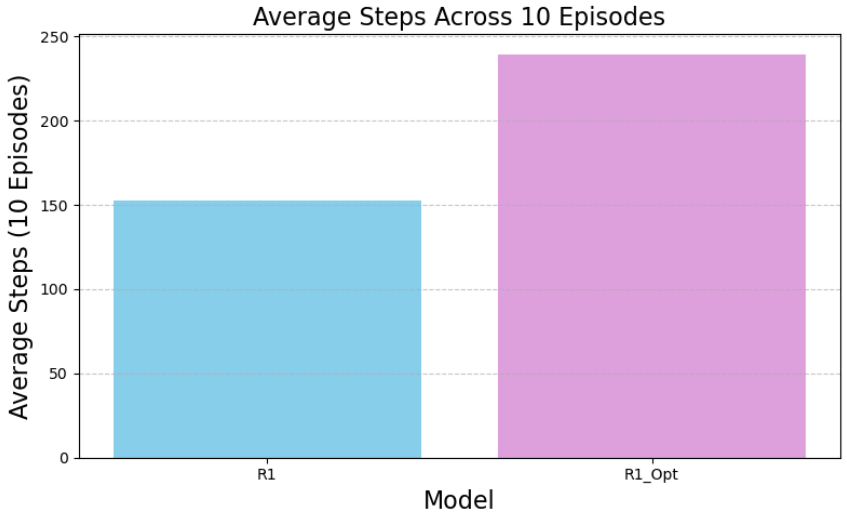

Assim, as implementações das alterações aos hiperparâmetros não melhoraram o desempenho do modelo.
Por isso, optamos por dar continuidade ao modelo anterior.

Parte experimental

TRPO original

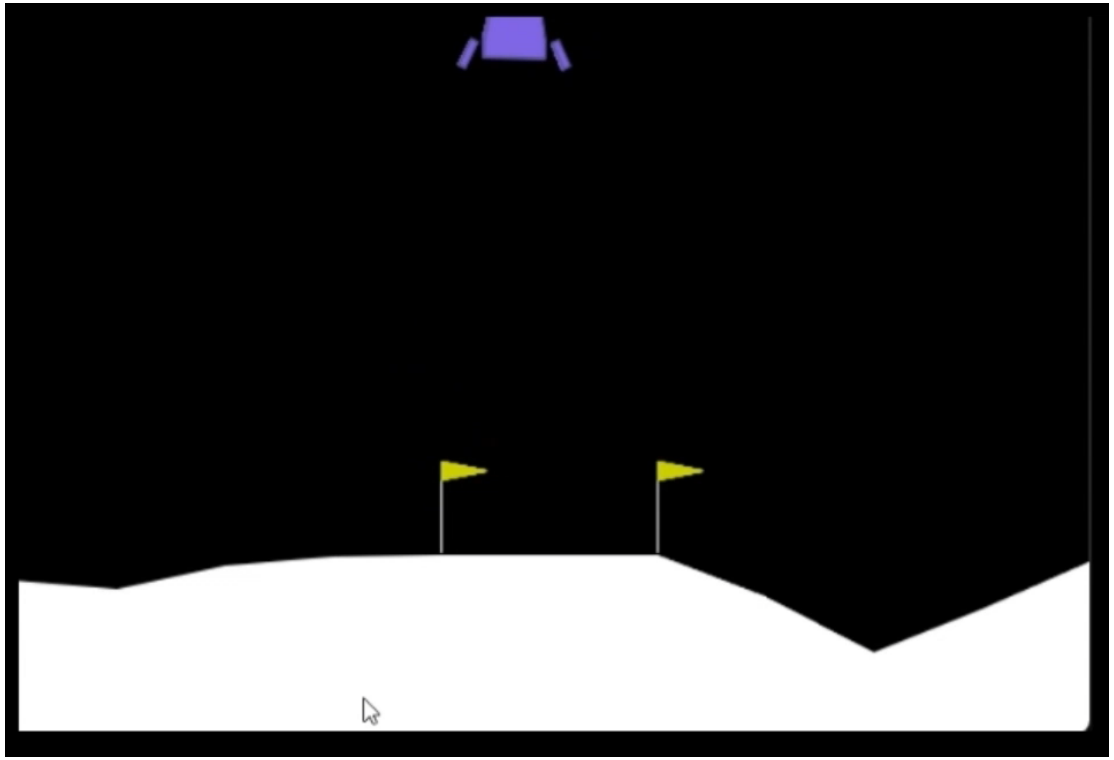

TRPO R1

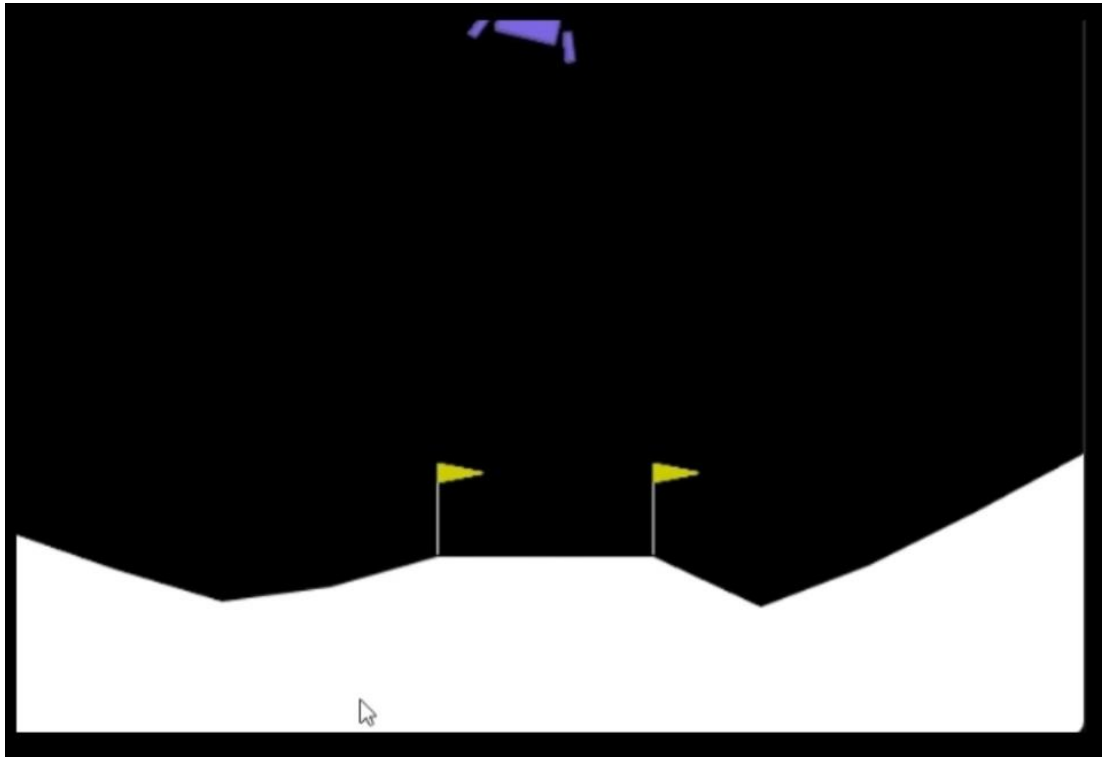

Conclusões

- Com a realização deste projeto concluímos que fomos capazes de desenvolver um sistema eficiente, de acordo com o objetivo inicial, na medida em que definimos as condições de recompensa e penalização, baseadas no comportamento do agente.
- Assim, definimos um sistema, no qual o agente recebe pontos por aterrar de forma suave, precisa e segura no solo, isto é, aterrar com as duas pernas.
- Da mesma forma, o agente sofre penalidades quando comete erros de aterragens bruscas ou quando está fora da plataforma. Por isso, procuramos otimizar o desempenho do agente, incentivando-o a reduzir a sua velocidade vertical e horizontal, durante o período de aterragem.