

Assignment #4: Anonymization of a Dataset with Utility and Risk Analysis

Segurança e Privacidade

Inês Neves ----- up202206252

Maria Beatriz Moreira ----- up202208293

Grupo PL03_4

1. INTRODUÇÃO

O trabalho proposto tem como objetivo realizar a anonimização de um *dataset* exemplo, fornecido pelos autores da ferramenta ARX.

A anonimização é um processo essencial na preservação da privacidade, uma vez que reduz o risco de reidentificação dos indivíduos, a partir dos dados disponíveis. Neste sentido, no decorrer deste relatório, apresentamos uma descrição do trabalho desenvolvido para a anonimização do dataset.

Inicialmente, realizamos a análise do conjunto de dados original, classificando os atributos em: “Identifying”, “Quasi-Identifying” (QIDs), “Sensitive” ou “Insensitive”, tendo em conta os respetivos valores de distinção e separação.

Posteriormente, caracterizamos e analisamos os riscos de privacidade do dataset na sua forma original, avaliando o risco de reidentificação associado.

De seguida, aplicamos os modelos de privacidade ao conjunto de dados e procedemos a uma análise de desempenho de cada um destes modelos. Esta análise inclui a comparação do risco de reidentificação do dataset anonimizado em relação ao dataset original, a avaliação do nível de utilidade, através de métricas apropriadas e o efeito do nível de supressão e modelo de codificação nos resultados.

Testamos, ainda, diferentes modelos de privacidade e fomos ajustando os diversos valores para os parâmetros correspondentes, de modo a conseguirmos obter um método de anonimização que consideramos bastante eficaz para anonimizar os dados.

2. ANÁLISE E CLASSIFICAÇÃO DOS ATRIBUTOS

A partir da análise do dataset, classificamos os atributos da seguinte forma:

- Quasi-Identifying: Sex, Age, Education, Native-Country, Occupation, Workclass, Salary-Class
- Sensitive: Race, Marital-status

Esta classificação foi realizada com base nos conceitos de *distinction* e *separation*, definidos seguidamente:

→ ***Distinction***: capacidade de um atributo (ou conjunto de atributos) de identificar com facilidade indivíduos dentro de um dataset. Quanto maior o número de categorias únicas que um atributo possui, maior é o seu poder de *distinction*.

Um atributo com um alto valor de *distinction* permite que cada indivíduo seja identificado de forma única, ou quase única, dentro do dataset. Isto significa que quanto maior for o valor

de *distinction*, maior é o risco de reidentificação, já que atributos com muitas categorias únicas podem ser utilizados para identificar indivíduos específicos quando combinados com outros atributos.

→ **Separation**: capacidade de um atributo (ou conjunto de atributos) para separar grupos de indivíduos dentro de um dataset, de forma a que estes grupos tenham características distintas.

Um alto valor de *separation* significa que o atributo divide a população em vários grupos pequenos e distintos, pelo que em combinação com outros atributos, aumenta o risco de reidentificação. A avaliação da *separation* ajuda a identificar quais combinações de atributos podem precisar de anonimização para proteger a privacidade dos indivíduos.

No contexto de anonimização de dados, tanto a *distinction* quanto a *separation* são usadas para avaliar o risco de reidentificação e determinar quais atributos devem ser protegidos ou transformados para garantir a privacidade dos indivíduos no dataset.

Assim, apresentamos seguidamente a justificação para a classificação de cada atributo.

Quasi-Identifying Attributes (QIDs)

“Quasi-Identifying Attributes” (QIDs) são atributos que, embora não identifiquem diretamente um indivíduo, podem levar à reidentificação, quando combinados com outros atributos.

Classificamos como “Quasi-Identifying” os seguintes atributos:

1. Sex (sexo)

O atributo “Sex” possui apenas duas categorias (masculino e feminino), o que facilita a distinção entre diferentes indivíduos no dataset. O seu valor de *distinction* é de 0.03514%, o que pode ser considerado muito baixo, indicando que isoladamente, não é um bom identificador.

No entanto, o seu valor de *separation* é relativamente alto (51.26559%), o sugere que “Sex”, quando combinado com outros atributos, pode diferenciar significativamente grupos de indivíduos, aumentando o risco de reidentificação.

Por exemplo, ao combinar o atributo sexo com idade ou com ocupação, observamos que os valores de *separation* aumentam consideravelmente (para 96.66164% ou 92.7607%, respetivamente), ou seja, é possível identificar indivíduos de forma mais precisa - num grupo de pessoas com a mesma ocupação e idade, o sexo pode ser o fator determinante para identificar um indivíduo específico.

Por estes motivos, classificamos “Sex” como “Quasi-Identifying”.

2. Age (idade)

O atributo “Age” apresenta uma ampla gama de valores, que variam entre os 17 e os 90 anos, dependendo da idade do indivíduo. Verificamos, deste modo, que o seu valor de *distinction* é o mais elevado: 0.6676% (quando comparado com os restantes atributos, individualmente), indicando que é possível uma distinção precisa entre indivíduos de diferentes faixas etárias, com base apenas neste atributo.

Simultaneamente, o valor de *separation* é também o mais elevado (94.38234%), o que torna a idade um atributo muito eficaz para diferenciar indivíduos.

A alta *distinction* significa que a idade, por si só, pode identificar um indivíduo de maneira única em muitos casos. Para além disso, quando combinada com outros atributos, a idade pode criar grupos muito específicos, aumentando o risco de reidentificação. Verifica-se, por exemplo, que quando se combina este atributo com o nível de educação e a ocupação, estes valores aumentam ainda mais, ficando com uma *separation* de 30.955573% e uma *distinction* de 99.85564%. Tal significa que se torna relativamente fácil identificar um indivíduo sabendo apenas 3 características acerca do mesmo: por exemplo, saber que uma pessoa tem 45 anos, possui um doutorado e trabalha no setor privado reduz significativamente o grupo de possíveis indivíduos.


Por estes motivos, classificamos “Age” como “Quasi-Identifying”.

3. Education (Nível de Educação)

O atributo "Education" inclui as seguintes categorias: Bachelors, Some-college, 11th, HS-grad, Prof-school, Assoc-acdm, Assoc-voc, 9th, 7th-8th, Masters, Doctorate, entre outros; representantes dos diferentes graus de educação que os indivíduos podem ter alcançado.

Com uma *distinction* de 0.2811%, "Education" permite diferenciar de forma significativa os indivíduos do dataset. Embora este valor não seja extremamente alto, podemos considerar que a *distinction* é significativa, indicando que existem várias categorias distintas que podem isolar grupos pequenos de indivíduos.

Com um valor de *separation* de 82.05174%, o atributo "Education" é altamente eficaz em dividir o dataset em subgrupos pequenos. Isto significa que, ao ser combinado com outros



atributos, como a idade, a ocupação e o tipo de emprego, pode-se reduzir significativamente o tamanho dos grupos de indivíduos, aumentando o risco de reidentificação.

Visto que quer os valores da *distinction* como da *separation* são bastante elevados, podemos concluir que o nível de educação é um forte identificador quando combinado com outros atributos.

Por exemplo, saber que uma pessoa tem um doutorado e uma idade específica reduz bastante o número de indivíduos correspondentes no dataset, uma vez que combinando estes 2 atributos os valores de *distinction* e *separation* aumentam para 7.55446% e 98.97059%, respetivamente. Estes valores tornam-se ainda mais elevados quando os combinamos com um outro atributo, por exemplo, ocupação (como referido previamente).

Por estes motivos, classificamos “Education” como “Quasi-Identifying”.

4. Native-country (País de origem)

O atributo “Native-country” inclui categorias como United States, England, India, Japan, Italy, Poland, entre outros, representando os diversos países de origem dos indivíduos no dataset.

O seu valor de *distinction* é de 0.70274%, o que evidencia que é possível diferenciar os indivíduos do dataset de maneira significativa. Embora o valor de *distinction* não seja extremamente elevado, podemos considerar que é suficientemente alto para indicar que o país de origem pode isolar grupos de indivíduos com base nesta característica.

Relativamente ao valor de *separation*, este é bastante baixo (15.25396%) o que sugere que, isoladamente, “Native-country ” não cria grupos tão pequenos e específicos como os outros atributos.

Deste modo, a inclusão de “Native-country” como Quasi-Identifying, baseia-se novamente no facto de que, quando combinado com outros atributos, pode aumentar o risco de reidentificação, o que é evidenciado pelo aumento dos valores de *distinction* e *separation*, quando são avaliados em conjunto, por exemplo, os atributos idade, nível de educação e país de origem: a *distinction* passa a ser de 14.66971% e a *separation* 99.08621%.

Por estes motivos, classificamos “Native-country” como “Quasi-Identifying”.

5. Workclass (Tipo de Emprego)

O atributo "Workclass" engloba uma variedade de categorias que descrevem os diferentes tipos de empregos que os indivíduos ocupam, nomeadamente, Federal-gov, State-gov, Local-gov, Private, Self-employed-inc, Self-employed-not-inc, without-pay e never-worked.

O seu valor de *distinction* é de 0.12298% e, embora não seja alto, indica que o tipo de emprego pode contribuir para a diferenciação entre os indivíduos.

Por outro lado, quando analisamos o valor de *separation*, concluímos que este é relativamente elevado (57.92789%), o que, mais uma vez, sugere que quando combinado com outros atributos, o tipo de emprego pode criar grupos distintos de indivíduos, aumentando significativamente o risco de reidentificação. Ou seja, embora possa não ser um identificador forte por si só, a sua capacidade de diferenciar grupos de indivíduos aumenta se o combinarmos com outros atributos.

Por exemplo, saber que uma pessoa trabalha no setor governamental e possui uma determinada idade e nível de educação, permite identificar o indivíduo de uma forma relativamente fácil - verificamos que quando combinamos estes três atributos, os valores de *distinction* e *separation* aumentam para 21.06465% e 99.52404%, respetivamente.

Por estes motivos, classificamos "Workclass" como "Quasi-Identifying".

6. Occupation (Ocupação)

O atributo "Occupation" fornece uma classificação das diferentes ocupações que os indivíduos exercem, abrangendo uma ampla gama de setores e atividades profissionais representadas no dataset, nomeadamente: Tech-support, craft-repair, exec-managerial, sales, farming-fishing, entre outros.

Este atributo tem uma *distinction* relativamente alta (0.22839%) e um valor de *separation* também muito elevado (89.04276%), o que significa que é um atributo forte para diferenciar indivíduos e criar grupos pequenos e específicos, por si só. Consequentemente, torna-se um identificador ainda mais forte quando é combinado com outros atributos.

Analisando os valores de *separation* e *distinction*, verificamos que quando juntamos a ocupação com a idade e o nível de educação, ocorre um aumento destes valores para 30.95573% e 99.85564%, respetivamente. Concluímos também, através destes valores, que esta é a junção de 3 argumentos mais eficaz na reidentificação de indivíduos.

Por estes motivos, classificamos "Occupation" como "Quasi-Identifying".

7. Salary (Salário)

O atributo "Salary" possui apenas duas categorias ($\leq 50K$ e $> 50K$), o que facilita a distinção entre diferentes grupos económicos dos indivíduos no dataset.

O seu valor de *distinction* é de 0.03514%, o que pode ser considerado muito baixo, o que indica que isoladamente, não é um bom identificador. No entanto, o valor de *separation* é de 44.80569%, sugerindo que o salário, embora não identifique diretamente um indivíduo, pode ser combinado com outros atributos para criar grupos mais específicos e, portanto, facilitar a reidentificação.

Por exemplo, saber que alguém ganha acima de 50K e tem uma determinada idade e nível de educação pode reduzir significativamente o grupo de possíveis indivíduos, aumentando o risco de reidentificação. Tal é evidenciado pelo facto de, quando o salário é combinado com o nível de educação e a idade, o valor de *distinction* aumenta para 11.56008% e o de *separation* para 99.39544%.

Por estes motivos, classificamos "Salary" como "Quasi-Identifying".

Sensitive Attributes

"Sensitive Attributes" são atributos que codificam propriedades com as quais os indivíduos não desejam ser associados e que, se revelados, podem causar danos emocionais, sociais ou financeiros aos indivíduos.


Classificamos como "Sensitive" os seguintes atributos:

8. Race (Raça)

O atributo "Race" no nosso dataset inclui as seguintes categorias: White, Black, Asian-Pac-Islander, Amer-Indian-Eskimo, Amer-Indian e Other.

A raça é uma informação altamente sensível que pode levar a discriminação ou preconceito em ambientes de trabalho, educacionais e sociais, se revelada. Consequentemente, pode provocar danos sociais e emocionais aos indivíduos, pelo que a proteção deste atributo é de extrema importância.

Embora o número de categorias deste atributo seja limitado, o seu valor de *distinction* (0.08784%) é relativamente baixo, o que evidencia que isoladamente a raça não é um forte identificador.



Comparando com outros atributos, como por exemplo "Idade" e "Nível de Educação", a *distinction* de "Race" é consideravelmente menor, o que sugere que "Race", é menos eficaz na diferenciação de indivíduos. Contudo, este valor pode ainda ser bastante significativo especialmente em determinados contextos. Por exemplo, numa comunidade predominantemente composta por um grupo racial específico, a presença de indivíduos de uma minoria racial torna-se mais destacada e, portanto, mais identificável.

Quanto ao seu valor de *separation* (21.524485%), embora este também seja moderadamente baixo, indica que a raça pode dividir o dataset em subgrupos menores quando combinada com outros atributos.

Analisando a combinação com outros atributos, verificamos mais uma vez que os valores de *distinction* e *separation* tornam-se mais elevados, chegando inclusivamente a ser de 12.82502% e 99.18495%, respetivamente, quando junta com a idade e o nível de educação.

Estes motivos levam-nos a considerar que o atributo raça, à semelhança de todos os referidos anteriormente, pode ser usado na sua forma original para identificar um indivíduo de uma forma relativamente fácil. Tal leva-nos a concluir que o podemos classificar como "Quasi-Identifying".

No entanto, dada a natureza extremamente sensível dos dados disponibilizados por este atributo, toda a discriminação e preconceito associados e ainda as consequências negativas na vida dos indivíduos que a revelação desta informação poderia causar, decidimos classificar este atributo como "Sensitive", além de "Quasi-identifying".

Tal significa que a anonimização deste atributo requer que medidas adicionais de proteção de privacidade sejam aplicadas, tais como a implementação de outros modelos de privacidade (no nosso caso utilizamos o I-diversity), de modo a mitigar os riscos associados e proteger os indivíduos de possíveis consequências adversas.

9. Marital-Status (Estado Civil)

O atributo "Marital-Status" apresenta as seguintes categorias: Married-civ-spouse, Divorced, Never-married, Separated, Widowed, Married-spouse-absent, Married-AF-spouse.

O valor de *distinction* para este atributo é 0.10541%, o que é relativamente baixo, ou seja, isoladamente, o estado civil não é um forte identificador. No entanto, o valor de *separation* é de 56.81889%, o que é moderadamente alto, indicando que este atributo pode dividir o dataset em subgrupos menores quando combinado com outros atributos.

Analisando os valores de *distinction* e *separation*, verificamos que assim como acontece com o atributo “Race”, podemos classificar este atributo como “Quasi-identifying”.

Contudo, consideramos que o estado civil é uma informação sensível, que pode levar a julgamentos sociais e discriminação se revelada, uma vez que a sua divulgação pode influenciar percepções e tratamentos diferenciados em ambientes de trabalho e na comunidade. Por exemplo, ser identificado como divorciado ou separado pode expor o indivíduo a preconceitos em determinados contextos sociais e profissionais.

Assim, consideramos que a proteção da informação do atributo “Marital-Status” é crucial para evitar danos sociais e emocionais aos indivíduos. Novamente, verifica-se a necessidade de aplicação de medidas adicionais de proteção de privacidade (como a implementação do I-diversity), para anonimizar o dataset e reduzir os riscos associados à reidentificação dos indivíduos.

3. ANÁLISE/CLASSIFICAÇÃO DOS RISCOS DE PRIVACIDADE DO DATASET ORIGINAL

Risco de reidentificação do Dataset Original

A análise de riscos de privacidade de um *dataset* na sua forma original é crucial para entender a exposição potencial dos indivíduos representados. Neste sentido, antes de aplicar qualquer técnica de anonimização, é muito importante avaliar o risco de reidentificação presente no dataset original.

O risco de reidentificação refere-se à possibilidade de identificar indivíduos específicos a partir de dados que foram considerados anonimizados. Seguidamente, iremos caracterizar e avaliar estes riscos no dataset em questão.

Para avaliarmos os riscos de reidentificação, consideramos os seguintes aspetos:

→ Valores de Distinction e Separation:

- Valores altos de *distinction* indicam que um atributo pode identificar indivíduos de maneira única.
- Valores altos de *separation* indicam que um atributo pode dividir o dataset em subgrupos menores e específicos.

→ Combinatoriedade dos Atributos:

- A reidentificação ocorre frequentemente quando múltiplos atributos são combinados. Por exemplo, a combinação de idade, nível de educação e ocupação pode criar subgrupos muito específicos, aumentando o risco de reidentificação.

Na tabela seguinte apresentamos alguns valores de *distinction* e *separation*, obtidos através do ARX, referentes à combinação dos atributos “Quasi-identifying”.

Quasi-identifying attributes	Distinction	Separation
age, education, workclass, occupation	50.15812%	99.93113%
age, marital-status, education, workclass, occupation	66.02249%	99.96707%
age, marital-status, education, workclass, occupation, salary-class	72.73366%	99.97932%
age, race, marital-status, education, workclass, occupation, salary-class	76.17709%	99.98294%
sex, age, marital-status, education, native-country, workclass, occupation, salary-class	78.09206%	99.98374%
sex, age, race, marital-status, education, workclass, occupation, salary-class	78.95292%	99.98502%
sex, age, race, marital-status, education, native-country, workclass, occupation, salary-class	80.34083%	99.98605%

Através da análise desta tabela, retiramos as seguintes observações:

- Combinação: age, education, workclass, occupation

Uma vez que metade dos indivíduos (50.15812%) são distintamente identificáveis, a combinação destes atributos já representa um risco significativo. A separation quase total (99.93113%) indica que os indivíduos podem ser separados em grupos muito pequenos, facilitando a reidentificação. A consequente implicação principal é que qualquer indivíduo com uma combinação única destes atributos pode ser identificado com alta precisão.

- Combinação: age, marital-status, education, workclass, occupation

A inclusão do estado civil aumenta ainda mais o risco de reidentificação, verificando-se que mais de dois terços dos indivíduos (66.02249%) são distintamente identificáveis. A separation elevada (99.96707%) mantém a capacidade de dividir os indivíduos em grupos menores. Isto sugere que a adição do estado civil torna os indivíduos ainda mais identificáveis, aumentando a precisão e o risco de reidentificação.

- Combinação: age, marital-status, education, workclass, occupation, salary-class

A inclusão do atributo “Salary” aumenta significativamente o risco de reidentificação. Com quase 73% dos indivíduos distintamente identificáveis, a combinação destes atributos permite a reidentificação dos indivíduos com alta precisão. Simultaneamente, a separation próxima de 100% indica que é possível separar os indivíduos quase completamente, expondo-os a riscos elevados de privacidade.

- Combinação: age, race, marital-status, education, workclass, occupation, salary-class

A inclusão da raça aumenta ainda mais os valores de distinction e separation. A raça, como atributo sensível, adiciona ainda uma camada de risco, pois pode levar a discriminação e preconceito. Verificando-se que mais de três quartos (76.17709%) dos indivíduos são distintamente identificáveis, concluímos que o risco de re-identificação é extremamente alto, o que torna necessário aplicar fortes medidas de proteção.

- Combinação: sex, age, marital-status, education, native-country, workclass, occupation, salary-class

A adição do sexo e do país de origem eleva ainda mais os valores de distinction e separation. Quase 80% dos indivíduos podem ser distintamente identificados, o que representa um risco de reidentificação muito alto. Isto sugere que a combinação destes atributos torna os indivíduos extremamente identificáveis, sendo necessárias medidas de anonimização robustas.

- Combinação: sex, age, race, marital-status, education, workclass, occupation, salary-class

A inclusão de raça juntamente com sexo, idade e outros atributos quase-identificadores resulta em valores de distinction e separation muito elevados. Com quase 79% dos indivíduos distintamente identificáveis, a proteção da privacidade torna-se crítica. As altas taxas de separation indicam a capacidade de dividir os indivíduos em grupos extremamente pequenos, causando um elevado risco de reidentificação.

- Combinação: sex, age, race, marital-status, education, native-country, workclass, occupation, salary-class

A combinação de todos os atributos maximiza os valores de distinction e separation. Observa-se que mais de 80% dos indivíduos são distintamente identificáveis. Simultaneamente, o valor de separation é de 99.98605%, o que representa a combinação com maior risco de reidentificação no dataset.

Desta forma, concluímos que **o dataset na sua forma original apresenta um elevado risco de reidentificação**, permitindo identificar os indivíduos com grande facilidade, quando é conseguido o acesso aos dados desprotegidos.

O elevado risco de reidentificação apresenta diversas **implicações e consequências** negativas para os indivíduos. De seguida, apresentamos algumas destas implicações:

→ Privacidade Individual

A reidentificação pode expor detalhes pessoais que os indivíduos preferem manter privados, nomeadamente informações confidenciais sobre saúde ou finanças, por exemplo. A divulgação indevida dos dados pode ainda resultar na perda de privacidade e possível exploração dessas informações por terceiros mal-intencionados, o que pode provocar problemas emocionais nos indivíduos identificados.

→ Discriminação e Preconceito

A divulgação de informações sensíveis pode levar à discriminação e preconceito em diferentes contextos (no local de trabalho, em ambientes educacionais ou até mesmo na sociedade, uma vez que um indivíduo reidentificado pode ser discriminado com base em atributos como a raça, estado civil ou outros aspetos pessoais, afetando negativamente a vida do mesmo.

→ Efeitos Psicológicos Negativos

Outra das implicações, causadas pela exposição dos dados pessoais, reside nos impactos psicológicos negativos que os indivíduos podem sentir.

A divulgação de informações sensíveis pode também prejudicar a reputação de um indivíduo, afetando as suas relações pessoais e profissionais.

→ Fraude e Roubo de Identidade

Os indivíduos cujas informações foram reidentificadas podem ser vítimas de fraude financeira ou roubo de identidade, resultando em perdas financeiras significativas e complexos processos de recuperação.

Todas estas razões e implicações justificam a extrema necessidade de anonimizar os dados do dataset original.

Assim, iremos agora descrever os modelos de privacidade implementados para a anonimização do dataset.

4. MODELOS DE PRIVACIDADE E DESEMPENHO

Aplicação de Modelos de Privacidade

Para mitigar os riscos de reidentificação e proteger os atributos sensíveis, aplicamos dois modelos de privacidade: k-Anonymity e l-Diversity.

k-Anonymity:

- Definição: Garante que cada registo é indistinguível de pelo menos $k-1$ outros registos em termos dos Quasi-Identifying Attributes.
- Aplicação: Configuramos k para garantir que grupos de pelo menos k registos compartilhem os mesmos valores para os QIDs. Isto reduz o risco de reidentificação, mas pode afetar a utilidade dos dados.

l-Diversity:

- Definição: Estende o conceito de k-Anonymity para garantir que dentro de cada grupo de k registos, haja pelo menos l valores distintos para qualquer atributo sensível. Isto protege contra ataques em que um invasor possa saber que todos os membros de um grupo compartilham o mesmo valor sensível.
- Aplicação: Configuramos l para garantir diversidade suficiente nos atributos sensíveis dentro de cada grupo k-anónimo.

A escolha dos modelos de privacidade foi feita após uma análise cuidadosa do equilíbrio entre privacidade e utilidade dos dados. Optamos por escolher o Distinct l-diversity para "marital-status" e "race" e k-Anonymity para os restantes atributos, pois esta combinação garante que cada grupo de registos partilha pelo menos dois valores distintos para o atributo específico, mantendo a diversidade e dificultando a identificação individual. Garante também que cada combinação única de atributos sensíveis é representada por pelo menos quatro registos, reduzindo o risco de identificação individual.

Para a escolha dos modelos fizemos diversas tentativas (que descrevemos mais à frente neste relatório), modificando os modelos de privacidade, bem como os parâmetros do mesmo. No entanto, a combinação referida é a que concluímos que atinge um equilíbrio adequado entre privacidade e utilidade, protegendo os dados contra a reidentificação sem comprometer significativamente a sua capacidade de análise estatística e preditiva.

Assim, os modelos de privacidade aplicados e os respectivos parâmetros são os seguintes:

Modelos de Privacidade:

- Distinct I-diversity :
 - Attribute: marital-status → Threshold (I): 2
 - Attribute: race → Threshold (I): 2
- k-Anonymity → Threshold (k): 4

Análise da performance dos modelos de privacidade

Após a anonimização dos dados, reavaliámos o risco de reidentificação para o conjunto de dados e fizemos a comparação com o risco de reidentificação do dataset original.


Observamos uma redução significativa no risco de reidentificação após a aplicação de k-Anonymity e I-Diversity. Com k-Anonymity, o risco foi reduzido ao assegurar que nenhum registo fosse único em relação aos QIDs. Com I-Diversity, a proteção adicional, relativamente aos identificadores sensíveis, foi garantida ao diversificar os valores dos atributos sensíveis dentro de cada grupo k-anónimo.

Comparação do risco de reidentificação:

Para compararmos o nível de reidentificação, utilizamos o “**Attacker models**” na aba “**Analyze Risk**”.

Para o dataset original e para o dataset anonimizado, obtivemos a seguinte overview:

Measure	Dataset Original	Dataset Anonimizado
Lowest prosecutor risk	3.84615%	0.16447%
Records affected by lowest risk	0.45678%	10.73257%
Average prosecutor risk	69.06184%	0.7767%
Highest prosecutor risk	100%	16.66667%
Records affected by highest risk	54.30429%	0.10591%




Estimated prosecutor risk	100%	16.66667%
Estimated journalist risk	100%	16.66667%
Estimated marketer risk	69.06184%	0.7767%
Sample uniques	54.30429%	0%
Population uniques	1.02434%	0%
Population model	PITMAN	DANKAR

A análise dos riscos de reidentificação nos conjuntos de dados original e anonimizados mostra uma redução significativa destes riscos após o processo de anonimização. A seguir, detalhamos as principais observações:

- Lowest Prosecutor Risk: Houve uma drástica redução no menor risco de reidentificação, o que demonstra que os dados se tornaram muito mais seguros.
- Records Affected by Lowest Risk: Um maior número de registos afetados pelo menor risco indica uma proteção mais abrangente, reduzindo os riscos de reidentificação para uma parcela maior dos dados.
- Highest Prosecutor Risk: A significativa redução do risco máximo demonstra que os registos mais vulneráveis estão muito mais protegidos.
- Estimated Prosecutor Risk: O risco estimado de reidentificação pelo promotor foi dramaticamente reduzido, o que evidencia que os dados estão muito menos suscetíveis à reidentificação, após a anonimização.
- Estimated Journalist Risk: A diminuição significativa deste risco reflete uma melhoria notável na proteção da privacidade.
- Estimated Marketer Risk: A redução substancial no risco de reidentificação pelo profissional de marketing destaca a eficácia da anonimização na proteção contra usos comerciais indevidos.
- Sample Uniques: A eliminação de registos únicos na amostra indica que não há mais identificadores diretos, melhorando significativamente a privacidade.
- Population Uniques: A ausência de registos únicos na população sugere que a anonimização foi eficaz em prevenir a reidentificação baseada em características únicas.

A imagem seguinte demonstra a análise de risco obtida no ARX, fazendo uma comparação para os valores antes e após a anonimização do dataset.



Os resultados demonstram que a **anonimização** foi extremamente **eficaz** na redução dos riscos de reidentificação em todos os níveis, incluindo os riscos estimados para promotores, jornalistas e profissionais de marketing.

Outra das razões que nos levam a considerar que a anonimização do dataset foi bem conseguida foi o facto de ter havido uma perda de dados muito reduzida: conseguimos que fossem eliminadas apenas 27 linhas do dataset, tal como exemplificado nas imagens seguintes:

Summary statistics		Distribution	Contingency	Class sizes	Properties	Classification models
Parameter	Value					
Scale of measure	Nominal scale					
Number of measures	5692					
Number of distinct values	13					
Mode	Exec-managerial					

Summary statistics		Distribution	Contingency	Class sizes	Properties	Classification models
Parameter	Value					
Scale of measure	Nominal scale					
Number of measures	5665					
Number of distinct values	13					
Mode	Exec-managerial					

Nível de Utilidade:

Medimos a utilidade dos dados utilizando o "**Quality model**" na aba "**Analyze Utility**" do ARX, que é uma ferramenta crucial para avaliar a utilidade dos dados anonimizados para tarefas de análise estatística.

Com base nos resultados do "**Dataset-level quality**", podemos tirar as seguintes conclusões:

- Intensidade de Generalização: A intensidade de generalização é alta, atingindo 81.75%, indicando que os dados foram generalizados de forma eficaz para proteger a privacidade, de forma a reduzir a capacidade de identificar indivíduos específicos.
- Granularidade: A granularidade dos dados anonimizados é alta, alcançando 87.99%. Tal sugere que a anonimização manteve um nível adequado de detalhe nos dados, permitindo análises estatísticas significativas sem comprometer excessivamente a privacidade.
- Entropia de Não-Unicidade (N.-U. entropy): A entropia de não-unicidade é moderadamente alta, registrando 68.03%. Isto aponta que a anonimização preservou uma quantidade razoável de variabilidade nos dados, tornando-os úteis para análises estatísticas.
- Discernibilidade: A discernibilidade é alta, atingindo 94.05%, o que sugere que a anonimização foi eficaz na redução da capacidade de identificação individual nos dados anonimizados.
- Tamanho Médio da Classe: O tamanho médio da classe é elevado, registrando 97.76%. Isto demonstra que os grupos anonimizados são suficientemente grandes para proteger a privacidade, reduzindo o risco de reidentificação.
- Erro Quadrático ao Nível do registo e do Atributo: O erro quadrático ao nível do registo e do atributo é moderadamente alto, indicando uma certa perda de utilidade dos dados anonimizados em termos de precisão preditiva.
- Erro Quadrático Específico da Agregação: O erro quadrático específico da agregação é baixo, atingindo apenas 14.70%. Tal indica que a anonimização foi capaz de preservar efetivamente a estrutura geral dos dados, mantendo a integridade das agregações.

Sintetizando, de um modo geral, os resultados indicam que a anonimização foi bem-sucedida na proteção da privacidade dos dados, mantendo um nível adequado de utilidade para análises estatísticas. No entanto, ocorreu uma certa perda de precisão preditiva (pouco significativa), como evidenciado pelos erros quadráticos.

Também medimos a utilidade dos dados utilizando o "**Classification Model**" na aba "**Classification Performance**" do ARX, que é uma ferramenta crucial para avaliar a utilidade dos dados anonimizados para tarefas de aprendizagem computacional.

Quando utilizamos o classifier: **Naive Bayes** (Sigma=1, Type=BERNOULLI), obtivemos as seguintes conclusões:


- Impacto da Anonimização: Para a maioria das variáveis, a accuracy pós-anonimização é comparável ou melhor do que a accuracy original, indicando que o processo de anonimização preservou bem a utilidade dos dados.
- Exceções: As variáveis "age", "race" e "marital-status" mostraram uma queda na accuracy e um Brier Skill Score negativo, indicando uma perda de utilidade significativa após a anonimização.
- Modelo de Referência: O Brier Skill Score negativo para algumas variáveis indica que a capacidade preditiva do modelo piorou em comparação com um modelo trivial.

Estes resultados indicam que, enquanto que, por um lado, a anonimização preservou a utilidade para algumas variáveis, outras sofreram uma redução na precisão preditiva.

Quando utilizamos o classifier: **Logistic Regression** (Lambda=1e-6, Learning Rate=1, Prior function=L1, Step offset=10000), obtivemos as seguintes conclusões:

- Impacto da Anonimização: Para a maioria das variáveis, a accuracy pós-anonimização é comparável ou melhor do que a accuracy original, indicando que o processo de anonimização preservou bem a utilidade dos dados.
- Exceções: As variáveis "age" e "race" mostraram uma accuracy pós-anonimização inferior à original, indicando uma perda de utilidade.
- Modelo de Referência: O Brier Skill Score positivo para a maioria das variáveis sugere que a capacidade preditiva do modelo melhorou ou foi mantida em relação ao modelo trivial.

Estes resultados indicam que a anonimização preservou ou até melhorou a utilidade para algumas variáveis, mas para outras ocorreu uma leve redução na precisão preditiva.



Desta forma, os resultados indicam que, embora a anonimização tenha preservado a utilidade dos dados para a maioria das variáveis, algumas variáveis específicas sofreram uma redução na precisão preditiva. Consideramos que tal se deve à aplicação do k-Anonymity, que causou alguma perda de precisão nos dados devido à generalização. Por outro lado, a aplicação de l-Diversity manteve uma maior variabilidade nos atributos sensíveis, preservando melhor a utilidade dos dados.

Efeito da Supressão e Generalização:

- **Supressão:**
 - Nível de Supressão: Com um limite de supressão de 51.6%, uma parte substancial dos dados foi removida para alcançar os critérios de anonimização.
 - Benefícios: Aumento da proteção da privacidade, minimizando os riscos de reidentificação.
 - Desvantagens: Redução na quantidade de dados disponíveis para análise, o que pode limitar a utilidade dos dados anonimizados.

- **Generalização:**
 - Intensidade de Generalização: A generalização para workclass (nível 2 de 3) e age (nível 4 de 5) indica que os dados foram agregados a níveis consideráveis para proteger a privacidade.
 - Benefícios: Proteção robusta contra a reidentificação, com uma redução significativa dos riscos identificados.
 - Desvantagens: Possível perda de detalhes importantes, o que pode afetar análises que dependem de dados granulares.

Os resultados indicam que a anonimização favoreceu a generalização em alguns atributos, como "age" e "workclass", onde a intensidade de generalização foi alta. Como sugere que estes atributos foram agrupados em categorias mais amplas, reduzindo a granularidade dos dados e, potencialmente, afetando a precisão preditiva.

Por outro lado, em atributos como "sex", "education" e "native-country", a intensidade de generalização foi menor, sugerindo que a anonimização favoreceu mais a supressão de certos valores. Isto pode ter levado a uma perda de detalhes nos dados anonimizados.

5. Coding Model

Descrição dos ajustes feitos nos parâmetros dos modelos

Aplicamos um modelo de codificação que combina generalização, microagregação e limites de supressão para equilibrar a privacidade e a utilidade dos dados.

Transformações aos Atributos:

• *Generalization hierarchy*

- » Attribute: workclass — Height: 3 — Minimum level: 0 — Maximum level: 2
- » Attribute: age — Height: 5 — Minimum level: 0 — Maximum level: 4

Modificamos a hierarquia da “Age”, uma vez que a sua distribuição estava enviesada à direita. Assim definimos a seguinte hierarquia de 4 níveis:

- Nível 0: As idades não são agrupadas em intervalos
- Nível 1: As idades são agrupadas em intervalos de dois anos
- Nível 2: As idades são agrupadas em intervalos de 8 anos
- Nível 3: As idades são agrupadas em intervalos de 32 anos
- Nível 4: O intervalo definido captura todas as idades presentes no dataset

• *Microaggregation function*

- » Attribute: education — Type: Mode — Clustering: No
- » Attribute: occupation — Type: Mode — Clustering: Yes
- » Attribute: salary-class — Type: Mode — Clustering: Yes
- » Attribute: native-country — Type: Mode — Clustering: Yes
- » Attribute: sex — Type: Mode — Clustering: Yes

As hierarquias de generalização para “Workclass” e “Age” permitiram uma flexibilidade adequada na anonimização, enquanto as funções de microagregação garantiram que os atributos como education, occupation, salary-class, native-country e sex fossem tratados de maneira a maximizar a utilidade dos dados anonimizados.

Configurações:

- Weights: occupation: 0.5 — salary-class: 0.5 — education: 0.5 — workclass: 0.5
race: 0.5 — native-country: 0.5 — sex: 0.5 — marital-status: 0.5 — age: 0.5

Aos atributos foram atribuídos pesos iguais para equilibrar a importância relativa de cada atributo na anonimização.

- Settings:
 - » Assume monotonicity: No
 - » Suppression limit: 0.516

A configuração do limite de supressão em 0.516 foi crucial para equilibrar a proteção da privacidade e a integridade dos dados anonimizados.

- Risk thresholds: Prosecutor risk: 0.25 — Journalist risk: 0.25 — Marketer risk: 0.25

Tal como referido anteriormente, para a escolha da melhor combinação de atributos de privacidade, realizamos múltiplas iterações para ajustar os parâmetros dos modelos de privacidade.

Variamos o valor de k por valores como 3, 4, 5, 10, 50 e 100, e o valor de l por valores como 2, 3, 5 e 10. Para além disso, experimentamos diferentes níveis de supressão e hierarquias de generalização. Estas iterações permitiram otimizar os resultados, alcançando um equilíbrio adequado entre privacidade e utilidade dos dados, levando-nos a escolher um k de valor 4 e um l de valor 2 para ambos os atributos sensíveis.

6. CONCLUSÃO

→ Reflexões sobre a eficácia dos modelos de privacidade utilizados

Os modelos de privacidade aplicados neste projeto (k -Anonymity e l -Diversity), demonstraram uma alta eficácia na proteção dos dados, conforme evidenciado pela redução significativa dos riscos de reidentificação:

- k -Anonymity

Threshold: $k=4$

Eficácia: Este modelo garantiu que cada registo fosse indistinguível de pelo menos outros três registos em termos de atributos quasi-identificadores (QIDs), reduzindo assim o risco de reidentificação individual. A generalização necessária para alcançar k -Anonymity causou alguma perda de precisão nos dados, conforme indicado pelos erros quadráticos, mas foi eficaz na proteção da privacidade.

- l -Diversity

Thresholds: $l=2$ para marital-status e race

Eficácia: A aplicação de l -Diversity garantiu que dentro de cada grupo de k registos, houvesse pelo menos dois valores distintos para os atributos sensíveis. Isto aumentou a diversidade dentro dos grupos, reduzindo ainda mais os riscos de reidentificação. Este modelo foi particularmente eficaz em preservar a variabilidade dos atributos sensíveis, mantendo uma maior utilidade dos dados anonimizados.

→ **Resumo dos resultados obtidos**

Com base na análise realizada, é evidente que a proteção da privacidade dos dados sensíveis é fundamental para mitigar os riscos de reidentificação e as suas consequências negativas.

Ao implementar modelos de privacidade como k-Anonymity e l-Diversity, foi possível reduzir significativamente o risco de reidentificação, garantindo ao mesmo tempo uma utilidade aceitável dos dados para análise estatística e preditiva.

A combinação cuidadosa de supressão, generalização e ajuste de parâmetros nos modelos de privacidade permitiu alcançar um equilíbrio entre privacidade e utilidade dos dados. Embora tenha havido uma perda mínima de dados e uma ligeira redução na precisão preditiva em algumas variáveis, os benefícios em termos de proteção da privacidade superam essas preocupações.

Em resumo, os resultados deste projeto destacam a importância da anonimização de dados sensíveis para proteger a privacidade dos indivíduos, enquanto ainda permite a utilidade dos dados.